Entregáveis do Projeto Aurora SIGER

Roteiro de desenvolvimento do trabalho em grupo. Cada seção abaixo corresponde a um entregável da atividade.

1.1 Organização e descrição da telemetria

Interpretar dados referentes a:

- Temperatura interna e externa
- Integridade estrutural (0/1)
- Níveis de energia (%)
- Pressão dos tanques
- Status dos módulos críticos

1.2 Algoritmo de verificação

Construir um algoritmo (fluxograma/pseudocódigo) capaz de decidir:

- **"PRONTO PARA DECOLAR"** ou **"DECOLAGEM ABORTADA"**

Com base em faixas seguras predefinidas para cada variável de telemetria.

1.3 Script em Python

Implementar a lógica do algoritmo em Python, simulando:

- Leitura dos dados de telemetria
- Execução das verificações contra faixas seguras
- Resultado final impresso: **"PRONTO PARA DECOLAR"** ou **"DECOLAGEM ABORTADA"**

1.4 Análise energética

Calcular autonomia inicial considerando:

- Capacidade total (kWh)
- Carga atual (%)
- Consumo estimado na decolagem

- Perdas energéticas

1.5 Análise assistida por IA

Solicitar à IA:

- Classificação dos dados de telemetria
- Identificação de possíveis anomalias
- Sugestões de risco

1.6 Reflexão crítica

Texto sobre:

- Ética e responsabilidade no uso de IA e automação em sistemas críticos
- Impacto social da exploração espacial
- Sustentabilidade tecnológica

Pipeline de Machine Learning

```
DATA LOADING & CLEANING → EDA → FEATURE ENGINEERING → DATA SPLITTING →
```

> **Nota:** Validação e Hyperparameter Tuning formam um ciclo iterativo — ajusta-se, valida-se, repete-se até encontrar a melhor configuração.

Etapa	O que faz
Data Loading & Cleaning	Carregar os dados brutos e tratar valores ausentes, duplicados ou inconsiste
EDA (Exploratory Data Analysis)	Visualizar distribuições, correlações e padrões para entender os dados ante
Feature Engineering	Criar, transformar ou selecionar variáveis que melhorem a capacidade predi
Data Splitting	Dividir em treino, validação e teste para avaliar o modelo em dados que ele r
Training	Ajustar os parâmetros do modelo aos dados de treino
Validation	Medir o desempenho em dados de validação para detectar overfitting ou un
Hyperparameter Tuning	Otimizar configurações externas ao modelo (ex: número de árvores, kernel)
Save Artefact	Serializar o modelo treinado (ex: `joblib`, `pickle`) para uso em produçã

```
# === import libraries ===

import numpy as np
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.ensemble import IsolationForest
```

```
np.random.seed(42)
n_samples = 100_000
anomalies_ratio = 0.03
n_anomalies = int(n_samples * anomalies_ratio)
```

```
tank_pressure_data = np.random.normal(loc=305, scale=15, size=n_sam

failure_prob = 1 / (1 + np.exp(-(tank_pressure_data - 340) / 5))
failure_prob = np.clip(failure_prob, 0, 1)

df_non_anomaly = pd.DataFrame({
    'internal_temp': np.random.normal(loc=22, scale=1.5, size=n_sam
    'external_temp': np.random.normal(loc=10, scale=8, size=n_sampl
    'structural_integrity': np.random.binomial(1, 1 - failure_prob)
    'energy': np.clip(np.random.normal(loc=98, scale=2, size=n_samp
    'vibration': np.random.normal(loc=0.3, scale=0.1, size=n_sample
    'tank_pressure': tank_pressure_data,
    'critical_modules': np.random.binomial(1, 1 - failure_prob, siz
})
```

```
# --- ANOMALY PRESSURE (shift distribution) ---
tank_pressure_anomaly = np.random.normal(loc=360, scale=25, size=n_

# Higher failure probability (more aggressive sigmoid)
failure_prob_anomaly = 1 / (1 + np.exp(-(tank_pressure_anomaly - 30
failure_prob_anomaly = np.clip(failure_prob_anomaly, 0, 1)

internal_temp =  np.concatenate(
       [np.random.normal(35,3,size=n_anomalies//2),
        np.random.normal(5,2,size=n_anomalies//2)]
        # need to divide it for the right number
    ) # internal temp (extreme)

np.random.shuffle(internal_temp)

df_anomaly = pd.DataFrame({
    'internal_temp': internal_temp,
    'external_temp': np.random.normal(loc=60, scale=20, size=n_anom
    'structural_integrity': np.random.binomial(1, 1 - failure_prob_
    'energy': np.clip(np.random.normal(loc=40, scale=15, size=n_anc
    'vibration': np.random.normal(loc=1.2, scale=0.4, size=n_anomal
    'tank_pressure' : tank_pressure_anomaly,
    'critical_modules': np.random.binomial(1,failure_prob_anomaly,


# === anomaly columns ===

df_non_anomaly['anomaly'] = 0
df_anomaly['anomaly'] = 1

init_dataframe = pd.concat([df_non_anomaly,df_anomaly]).reset_index
```

```
print(f'Dataframe shape: {init_dataframe.shape}')
```

```
Dataframe shape: (100000, 8)
```

```
init_dataframe.head(5)
```

	internal_temp	external_temp	structural_integrity	energy	vibr
0	24.613473	8.821301	1	97.030465	0.2
1	21.841330	3.264808	1	94.998383	0.3
2	21.895316	18.606012	1	99.018895	0.3
3	21.713747	26.772365	1	97.684462	0.2
4	22.831218	11.177638	1	97.510682	0.3

Próximas etapas: Gerar código com `init_dataframe` New interactive sheet

```
init_dataframe.describe()
```

	internal_temp	external_temp	structural_integrity	ener
count	100000.000000	100000.000000	100000.000000	100000.0000
mean	21.938870	11.479782	0.948010	96.0939
std	3.030864	12.124527	0.222008	10.3360
min	-1.344384	-25.311088	0.000000	0.0000
25%	20.953659	4.758315	1.000000	96.4860
50%	21.999259	10.286177	1.000000	97.9135
75%	23.045546	15.967211	1.000000	99.2982
max	45.327927	130.305995	1.000000	100.0000

EDA (Exploratory data analysis)

```
import seaborn as sns
import matplotlib.pyplot as plt
import plotly.express as px

# === Plot configurations ===
sns.set_style("dark", {
    "axes.facecolor": "black",
    "figure.facecolor": "black",
    "grid.color": "#222222", # Very faint grid
```

```
        "text.color": "white",
        "axes.labelcolor": "white",
        "xtick.color": "white",
        "ytick.color": "white"
    })
    sns.set_context('talk') # bold text for readable
    sns.despine() # remove the top and right spines

    def heatmap_plot(data:pd.DataFrame) -> None:
        plt.figure(figsize=(7.5,6))
        plt.title('Heatmap of the correlation between variables')
        corr = data.corr()
        mask = np.triu(np.ones_like(corr, dtype=bool)) # upper triangul
        sns.heatmap(corr,mask=mask,annot=True,fmt=".2f")
        plt.show()

    def distribution_plot(data: pd.DataFrame) -> None:

        n_vars = len(data.columns)
        n_cols = 2
        n_rows = (n_vars + n_cols - 1) // n_cols

        plt.figure(figsize=(16, 4*n_rows))

        for idx, col in enumerate(data.columns, start=1):

            plt.subplot(n_rows, n_cols, idx)

            sns.histplot(
                data[col],
                kde=True,
                bins=25,
                color="#4C72B0",
                edgecolor="black"
            )

            plt.title(f"Distribution of {col}", fontsize=12, fontweight
            plt.xlabel(col)
            plt.ylabel("Frequency")

        plt.suptitle("Feature Distributions", fontsize=18, fontweight="

        plt.tight_layout(rect=[0,0,1,0.96])
        plt.show()

    def boxplot_(data:pd.DataFrame):

      n_vars = len(data.columns)
```

```
n_cols = 3
n_rows = (n_vars + n_cols -1) // n_cols

plt.figure(figsize=(16,4*n_rows))
for idx, col in enumerate(data.columns):

      plt.subplot(n_rows, n_cols, idx + 1)

      sns.boxenplot(
          x=data[col],
          color="#4C72B0"
      )

      plt.title(f"{col}", fontsize=12, fontweight="bold")

plt.suptitle("Feature Distribution Overview", fontsize=18, fontwe

plt.tight_layout()
plt.show()
```

```
<Figure size 640x480 with 0 Axes>
```

```
def pairplot_data(data: pd.DataFrame):
    if data is None or data.empty:
        print("Dataframe is empty")
        return

    # No loop, no manual subplots needed
    # corner=True removes the mirrored top-half for better readabil
    sns.pairplot(data, hue='anomaly', corner=True, palette='coolwar
    plt.suptitle("Feature Inter-correlations by Anomaly", y=1.02, f
    plt.show()
```

```
pairplot_data(init_dataframe)
```

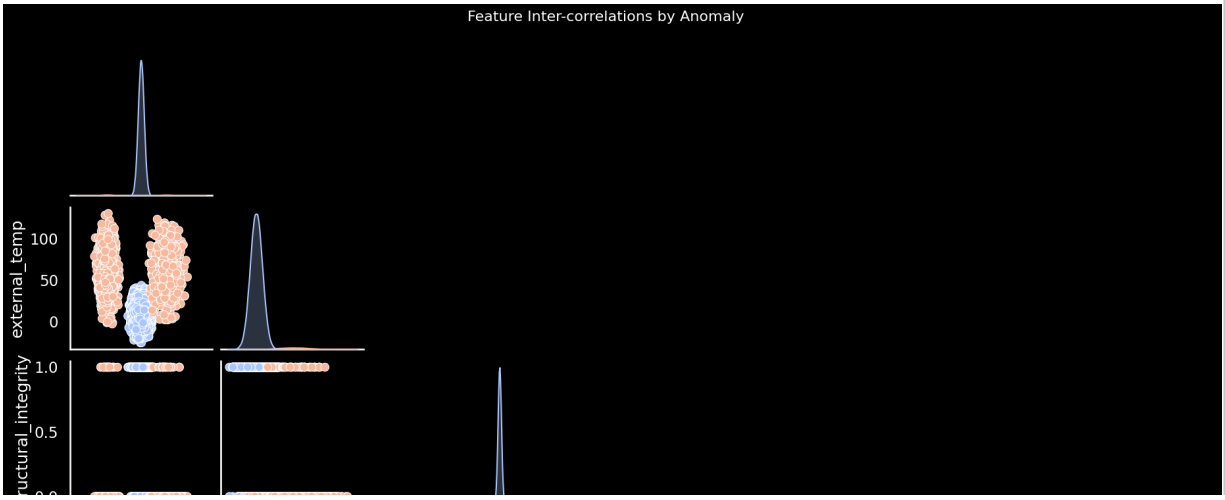

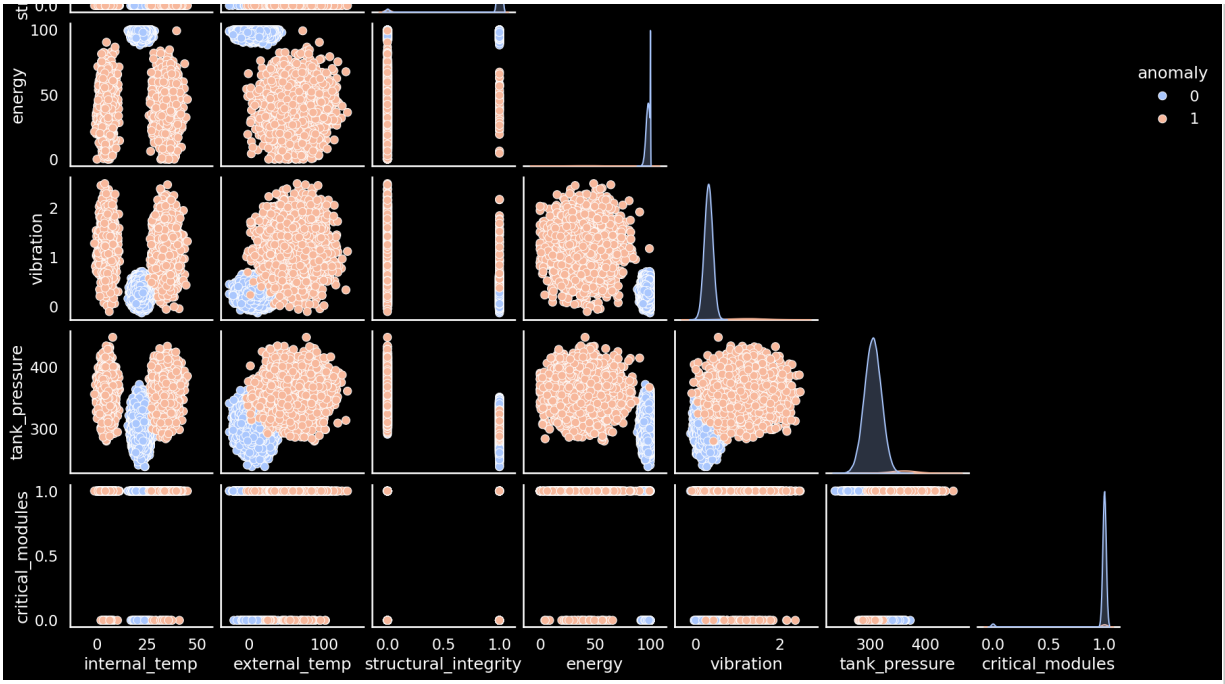
anomaly
0
1
energy
vibration
tank_pressure
critical_modules
internal_temp
external_temp
structural_integrity
energy
vibration
tank_pressure
critical_modules

```
import plotly.io as pio
pio.renderers.default = "colab"

def visualization_3D_anomaly(data: pd.DataFrame, x_axis: str, y_axi

    if data is None or data.empty:
        print("Dataframe is empty.")
        return

    required_cols = [x_axis, y_axis, z_axis, "anomaly"]

    for col in required_cols:
        if col not in data.columns:
            print(f"Column '{col}' not found in dataframe.")
            return

    fig = px.scatter_3d(
        data,
        x=x_axis,
        y=y_axis,
        z=z_axis,
        color="anomaly",
        opacity=0.5,
        title=f"3D Anomaly Visualization: {x_axis} vs {y_axis} vs {
    )

    fig.update_layout(
        scene=dict(
            xaxis_title=x_axis,
            yaxis_title=y_axis,
            zaxis_title=z_axis
        ),
        width=900,
        height=700,
        legend_title="Anomaly"
    )

    fig.show()


normal = init_dataframe.sample(12000) # 12000 samples for plotting

visualization_3D_anomaly(
    normal,
```

```
        "tank_pressure",
        "internal_temp",
        "vibration"
    )
```

3D Anomaly Visualization: tank_pressure vs internal_temp vs

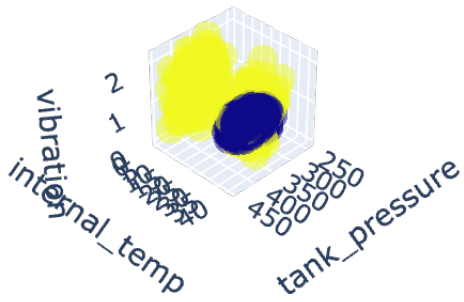

```
heatmap_plot(init_dataframe)
```

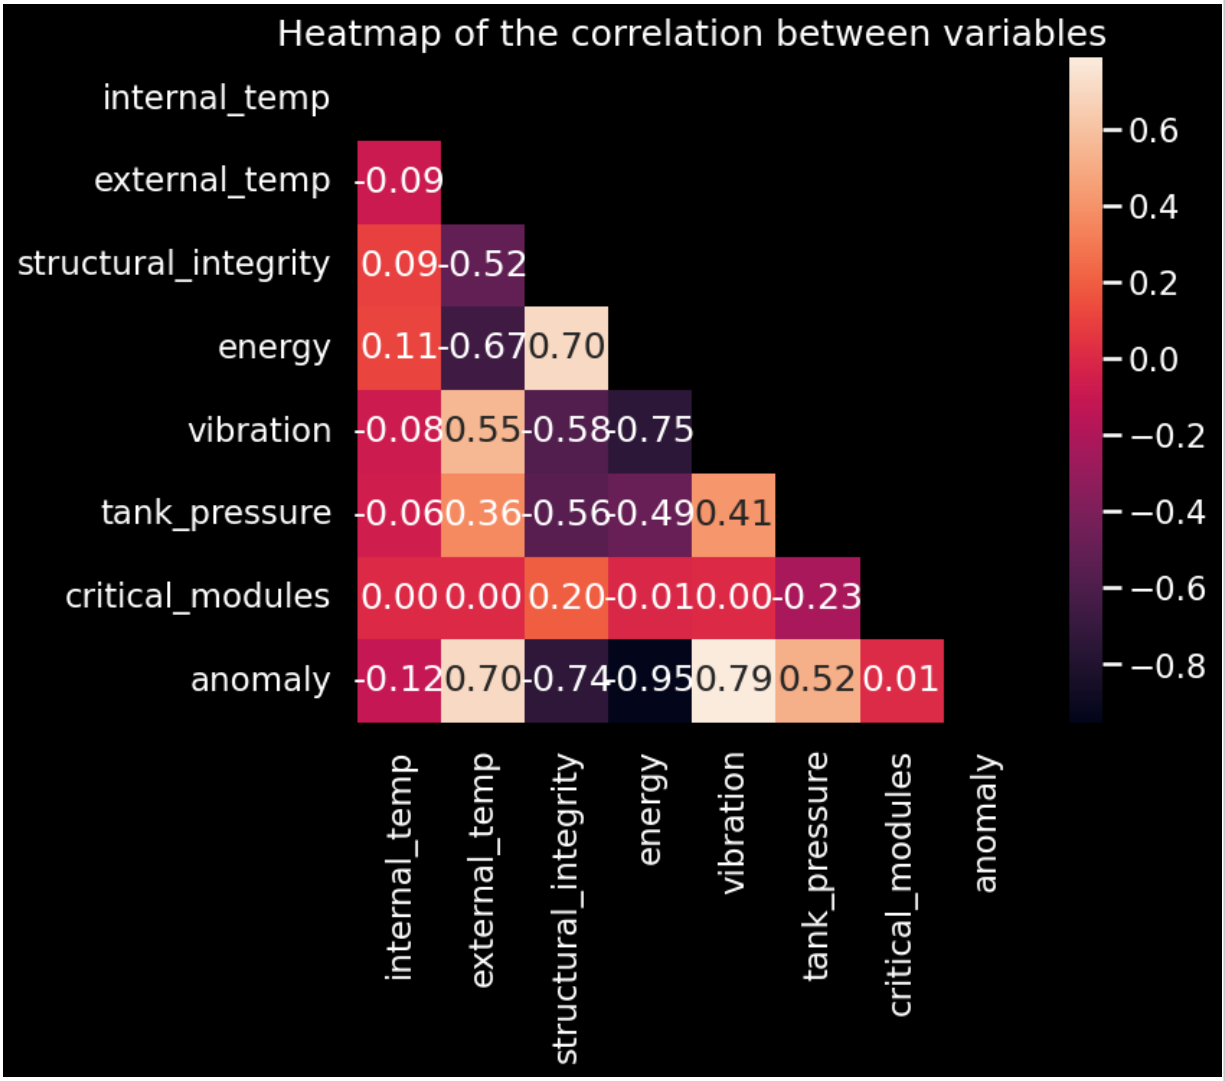

```
## exploring the data
plt.title("Value counts about structural_integrity")
init_dataframe['structural_integrity'].value_counts().plot(kind="ba
plt.tight_layout()
plt.show()
```

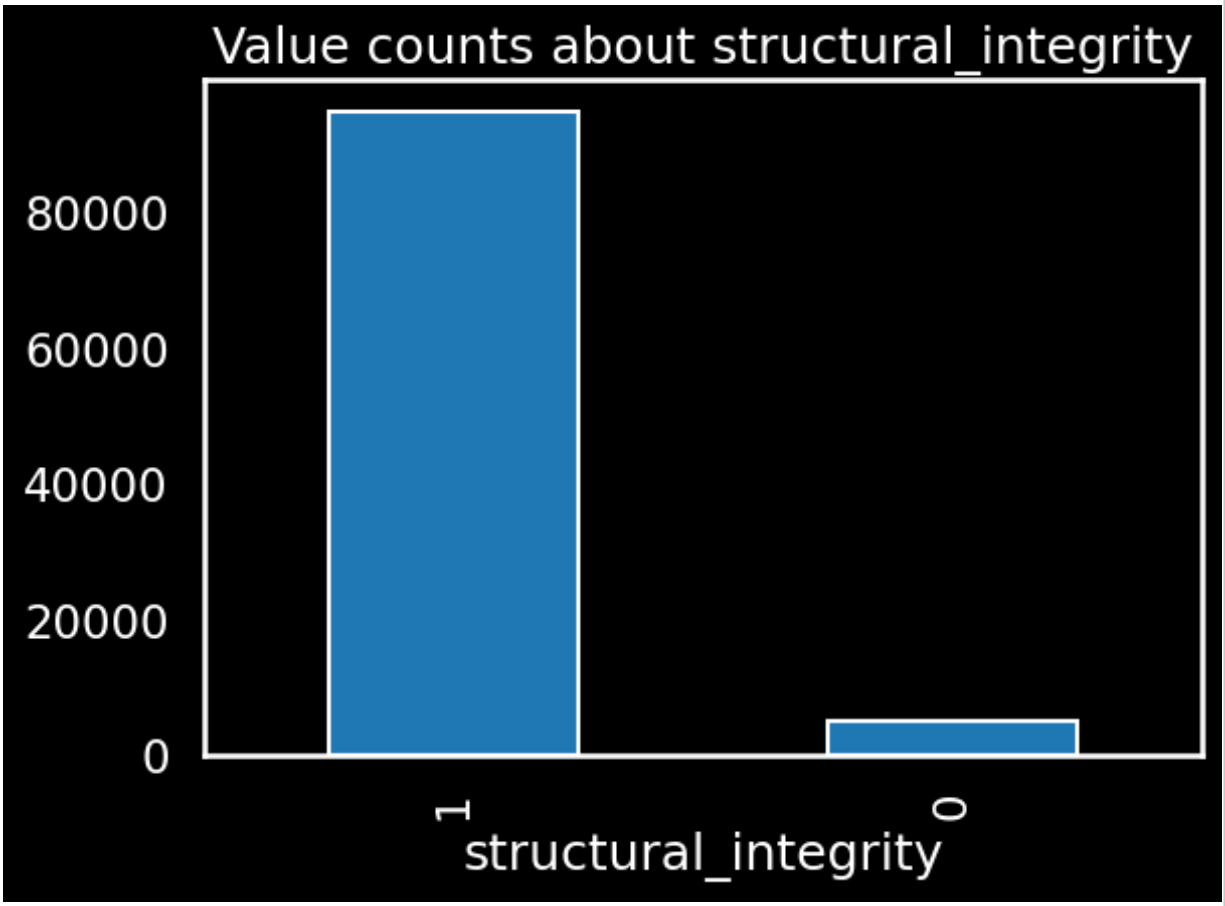


```
boxplot_(data=init_dataframe)
```

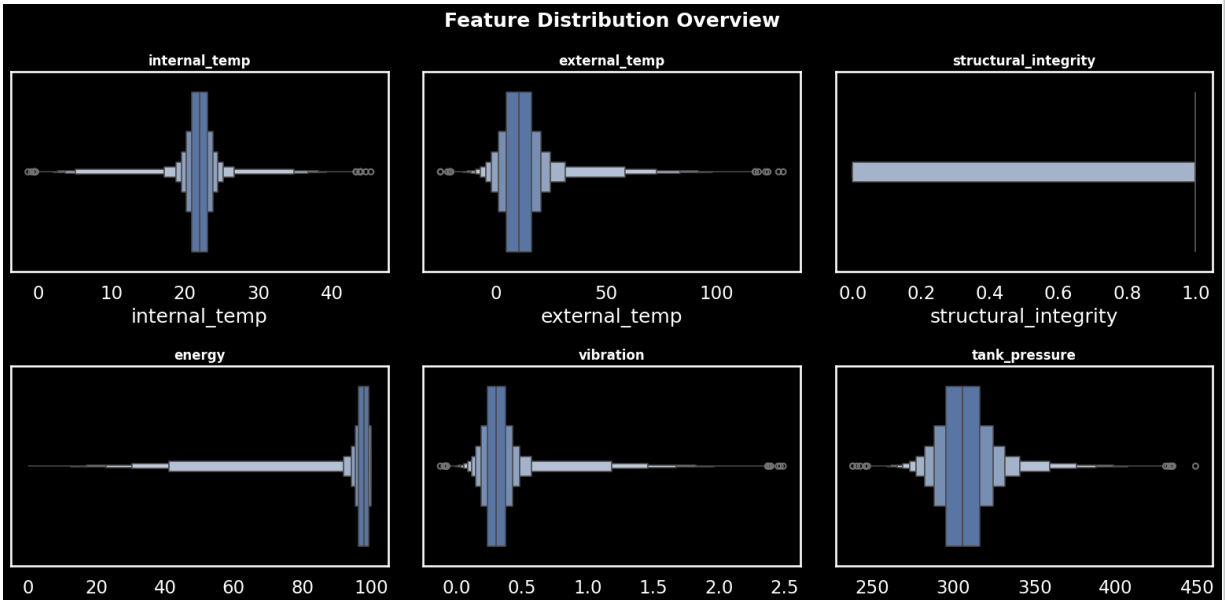

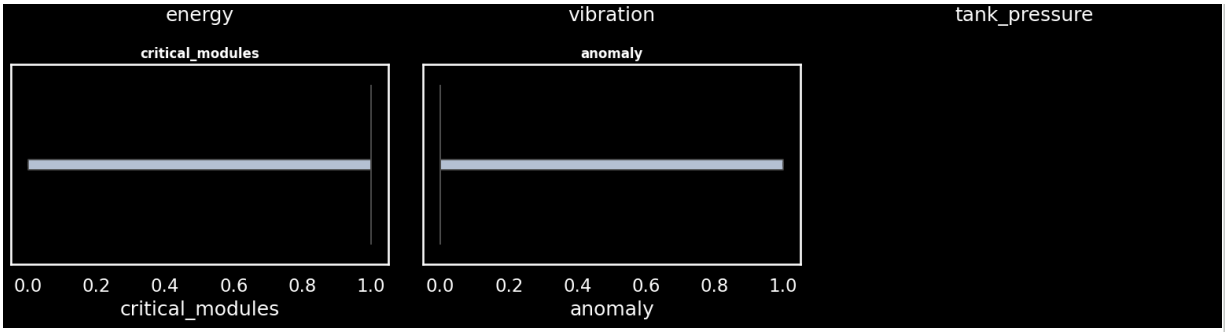


```
distribution_plot(data=init_dataframe)
```

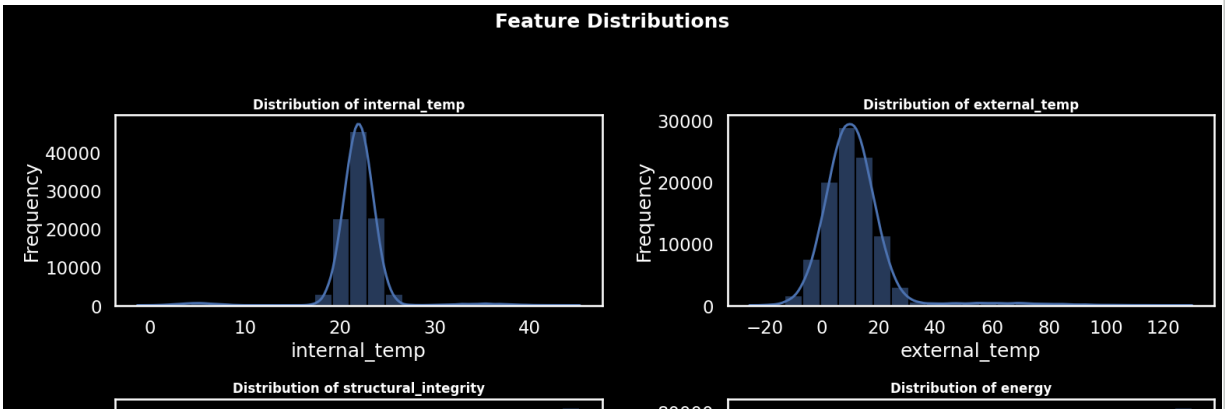

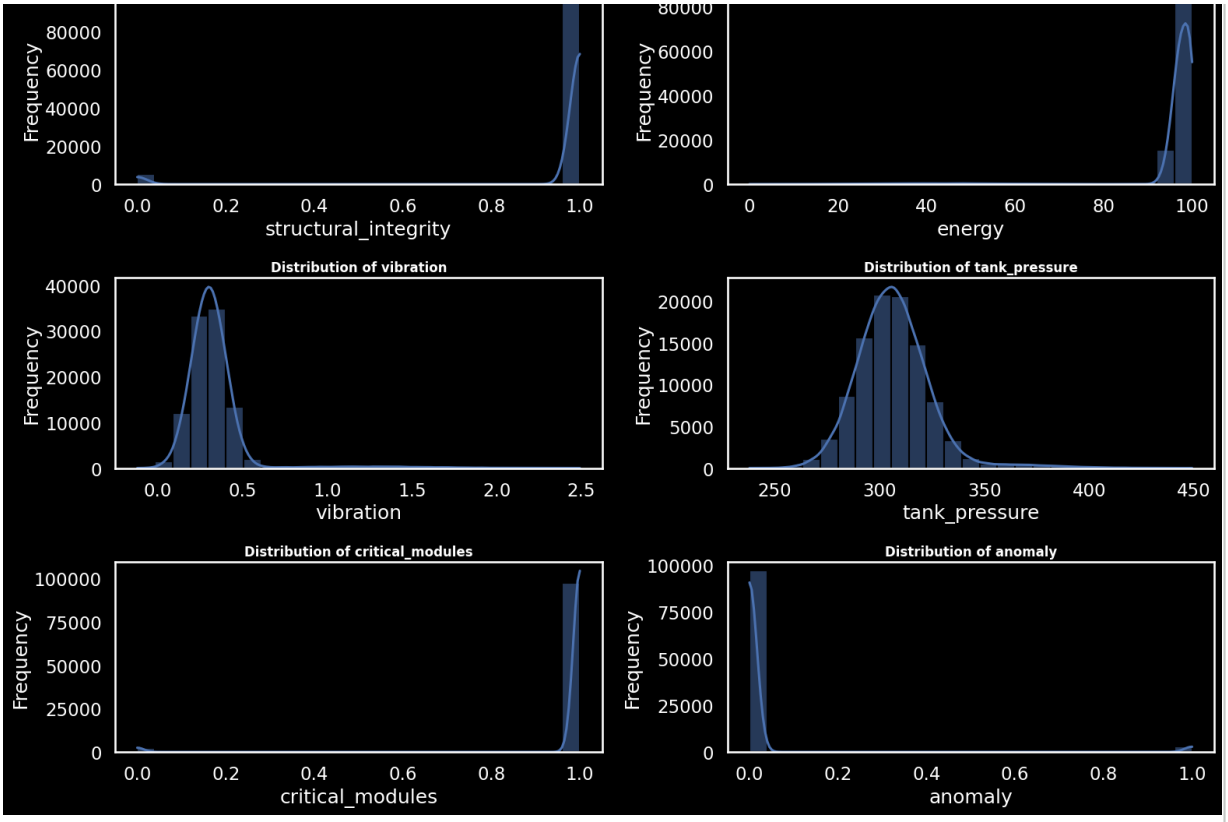
Frequency
structural_integrity
energy
Distribution of vibration
vibration
Distribution of tank_pressure
tank_pressure
Distribution of critical_modules
critical_modules
Distribution of anomaly
anomaly

Creating the models from scratch

```
class IsolationTreeNode:
  def __init__(self,feature=None,threshold=None,left=None,right=Non
    self.feature = feature
    self.threshold = threshold
    self.left = left
    self.right = right
    self.size = size
```

```
class  IsolationTree:

  def __init__(self,max_depth):

    self.max_depth = max_depth
    self.root = None

  def fit(self,X):

    self.root = self._grow_tree(X,depth=0)

  def _grow_tree(self, X, depth):

    n_samples, n_features = X.shape

    if depth >= self.max_depth or n_samples <= 1:
        return IsolationTreeNode(size=n_samples)

    feature = np.random.randint(0, n_features)

    min_val = X[:, feature].min()
    max_val = X[:, feature].max()

    if min_val == max_val:
        return IsolationTreeNode(size=n_samples)

    threshold = np.random.uniform(min_val, max_val)
```

```
        left_mask = X[:, feature] < threshold
        right_mask = X[:, feature] >= threshold

        # Prevent empty branches
        if np.sum(left_mask) == 0 or np.sum(right_mask) == 0:
            return IsolationTreeNode(size=n_samples)

        left = self._grow_tree(X[left_mask], depth + 1)
        right = self._grow_tree(X[right_mask], depth + 1)

        return IsolationTreeNode(feature, threshold, left, right)

    def path_length(self,x):
        return self._path_length(x,self.root,0)

    def _path_length(self,x,node,depth):

        if node.size is not None:
          return depth + self._c(node.size)

        if x[node.feature] < node.threshold:
          return self._path_length(x,node.left, depth + 1 )
        else :
          return self._path_length(x,node.right,depth + 1)

    def _c(self,n):
        """
        Computes the average path length of an unsuccessful search in a

        In the context of Isolation Forests, this value serves as a nor
        factor. It represents the 'expected' depth for a node in a tree
        from 'n' data points.

        If an actual data point has a path length significantly shorter
        theoretical average, it is considered more "isolated" and thus

        Args:
            n (int): Number of nodes/samples in the tree.

        Returns:
            float: The harmonic-based average path length.
        """

        if n <= 1:
          return 0

        # 0.5772156649 is the Euler-Mascheroni constant (gamma).
```

```
    # We use (log(n-1) + gamma) to efficiently approximate the
    # n-th Harmonic number, H(i).

    return 2 * (np.log(n - 1) + 0.5772156649) - (2 * (n - 1) / n)
```

```
class MyIsolationForest:

  def __init__(self,n_trees,sample_size):
    self.n_trees = n_trees
    self.sample_size = sample_size
    self.trees = []

  def fit(self,X):

    self.trees = []
    n_samples = X.shape[0]

    max_depth = int(np.ceil(np.log2(self.sample_size)))

    for _ in range(self.n_trees):

      idxs = np.random.choice(n_samples,self.sample_size,replace=Fa
      sample = X[idxs]

      tree = IsolationTree(max_depth)
      tree.fit(sample)

      self.trees.append(tree)

  def anomaly_score(self,X):

    scores = []

    for x in X:

      path_lengths = [tree.path_length(x) for tree in self.trees]

      avg_path = np.mean(path_lengths)

      c = self._c(self.sample_size)

      score = 2 ** (-avg_path / c)

      scores.append(score)

    return np.array(scores) # Changed from np.array(score)
```

```
    def _c(self,n):
      """
      Computes the average path length of an unsuccessful search in a

      In the context of Isolation Forests, this value serves as a nor
      factor. It represents the 'expected' depth for a node in a tree
      from 'n' data points.

      If an actual data point has a path length significantly shorter
      theoretical average, it is considered more "isolated" and thus

      Args:
          n (int): Number of nodes/samples in the tree.

      Returns:
          float: The harmonic-based average path length.
      """

      if n <= 1:
        return 0

      # 0.5772156649 is the Euler-Mascheroni constant (gamma).
      # We use (log(n-1) + gamma) to efficiently approximate the
      # n-th Harmonic number, H(i).

      return 2 * (np.log(n - 1) + 0.5772156649) - (2 * (n - 1) / n)


    def predict(self,X,contamination=0.03):

      scores = self.anomaly_score(X)

      threshold = np.percentile(scores,100 *  (1 - contamination))
      return np.where(scores >= threshold,-1,1) # -1 anomaly , 1 norm
```

```
from sklearn.metrics import classification_report, roc_auc_score
from sklearn.preprocessing import StandardScaler

scaler = StandardScaler()


X = init_dataframe.drop(columns=["anomaly"]).values
y = init_dataframe["anomaly"].values

X_train, X_test, y_train, y_test = train_test_split(
    X, y,
    stratify=y,
    test_size=0.2,
    random_state=42
)

X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)

my_model = MyIsolationForest(
    n_trees=100, # Changed from n_trees
    sample_size=256   # Changed from sample_size
)
```

```
# ===== SCRATCH MODEL =====

my_model.fit(X_train) # Added: Fit the custom Isolation Forest mode

train_scores = my_model.anomaly_score(X_train)

threshold = np.percentile(train_scores, 97)

test_scores = my_model.anomaly_score(X_test)

preds = np.where(test_scores >= threshold, 1, 0)

print("Scratch Model")
print(classification_report(y_test, preds))

scratch_auc = roc_auc_score(y_test, test_scores)
print("Scratch ROC AUC:", scratch_auc)


# ===== SKLEARN MODEL =====

sk_model = IsolationForest(
```

```
    n_estimators=100,
    max_samples=256,
    contamination=0.03,
    random_state=42
)

sk_model.fit(X_train)

sk_preds = sk_model.predict(X_test)
sk_preds = np.where(sk_preds == -1, 1, 0)

print("Sklearn Model")
print(classification_report(y_test, sk_preds))

sk_scores = -sk_model.decision_function(X_test)

sk_auc = roc_auc_score(y_test, sk_scores)

print("Sklearn ROC AUC:", sk_auc)
```

```
Scratch Model
              precision    recall  f1-score   support

           0       1.00      1.00      1.00     19400
           1       0.95      0.95      0.95       600

    accuracy                           1.00     20000
   macro avg       0.97      0.97      0.97     20000
weighted avg       1.00      1.00      1.00     20000

Scratch ROC AUC: 0.9997515463917527
Sklearn Model
              precision    recall  f1-score   support

           0       1.00      1.00      1.00     19400
           1       0.99      0.99      0.99       600

    accuracy                           1.00     20000
   macro avg       1.00      0.99      0.99     20000
weighted avg       1.00      1.00      1.00     20000

Sklearn ROC AUC: 0.9999746563573884
```

```
plt.hist(test_scores[y_test == 0], bins=50, alpha=0.6, label="Norma
plt.hist(test_scores[y_test == 1], bins=50, alpha=0.6, label="Anoma

plt.axvline(threshold, color='red', linestyle='--', label='Threshol

plt.title("Isolation Forest Score Distribution")
plt.xlabel("Anomaly Score")
plt.ylabel("Frequency")
plt.legend()

plt.show()
```

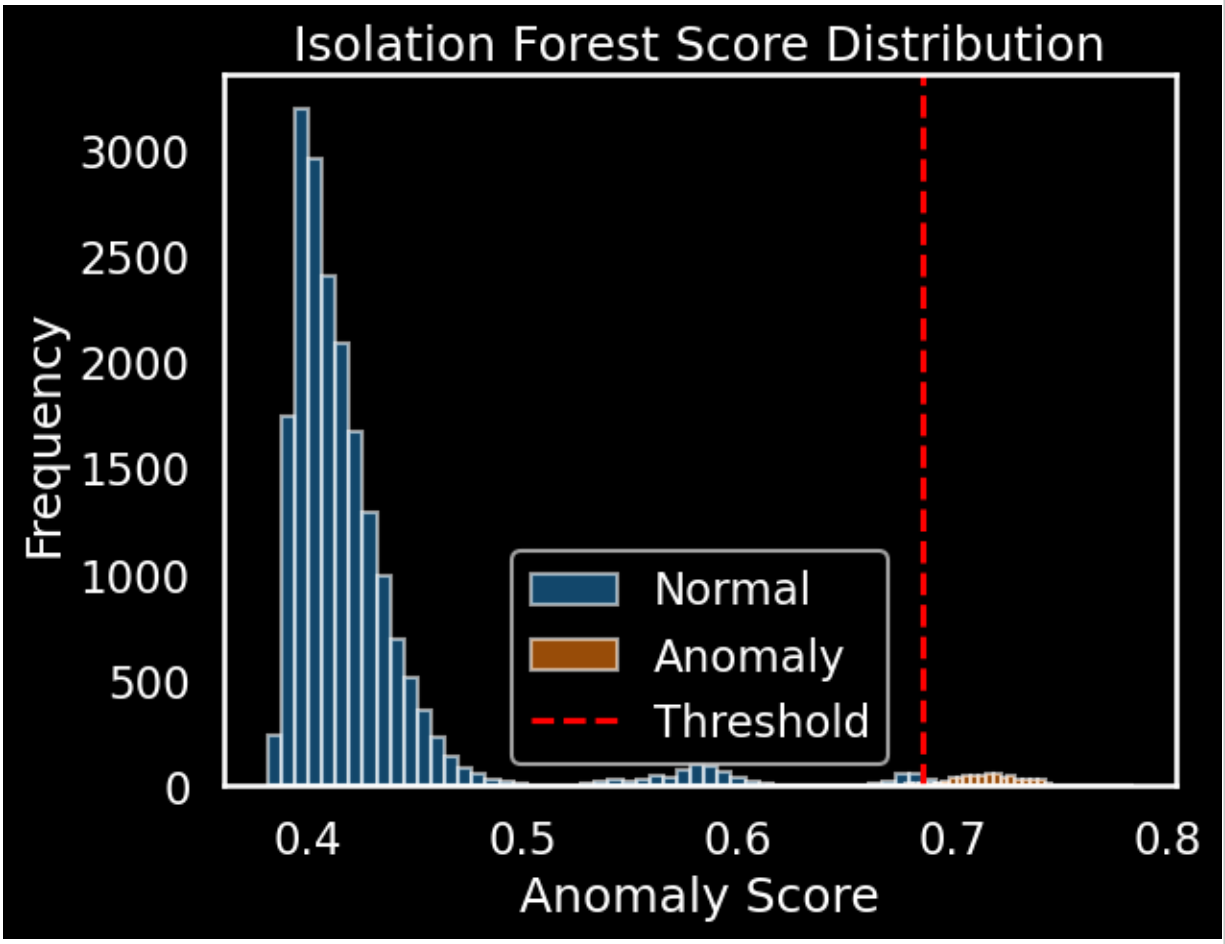

```
# === Comparing model metrics ===

from sklearn.metrics import accuracy_score, precision_score, recall

metrics = ["Accuracy", "Precision", "Recall", "F1", "ROC AUC"]

# Scratch metrics
scratch_accuracy = accuracy_score(y_test, preds)
scratch_precision = precision_score(y_test, preds)
scratch_recall = recall_score(y_test, preds)
scratch_f1 = f1_score(y_test, preds)

# Sklearn metrics
sk_accuracy = accuracy_score(y_test, sk_preds)
sk_precision = precision_score(y_test, sk_preds)
sk_recall = recall_score(y_test, sk_preds)
sk_f1 = f1_score(y_test, sk_preds)

sklearn_scores = [
    sk_accuracy,
    sk_precision,
    sk_recall,
    sk_f1,
    sk_auc
]

scratch_scores = [
    scratch_accuracy,
    scratch_precision,
    scratch_recall,
    scratch_f1,
    scratch_auc
]
```

```
x = np.arange(len(metrics))
width = 0.35

plt.figure(figsize=(8,5))

plt.bar(x - width/2, sklearn_scores, width, label="Sklearn")
plt.bar(x + width/2, scratch_scores, width, label="Scratch")

plt.xticks(x, metrics)
plt.ylabel("Score")
plt.title("Isolation Forest: Sklearn vs Scratch Implementation")
plt.legend()

plt.show()
```

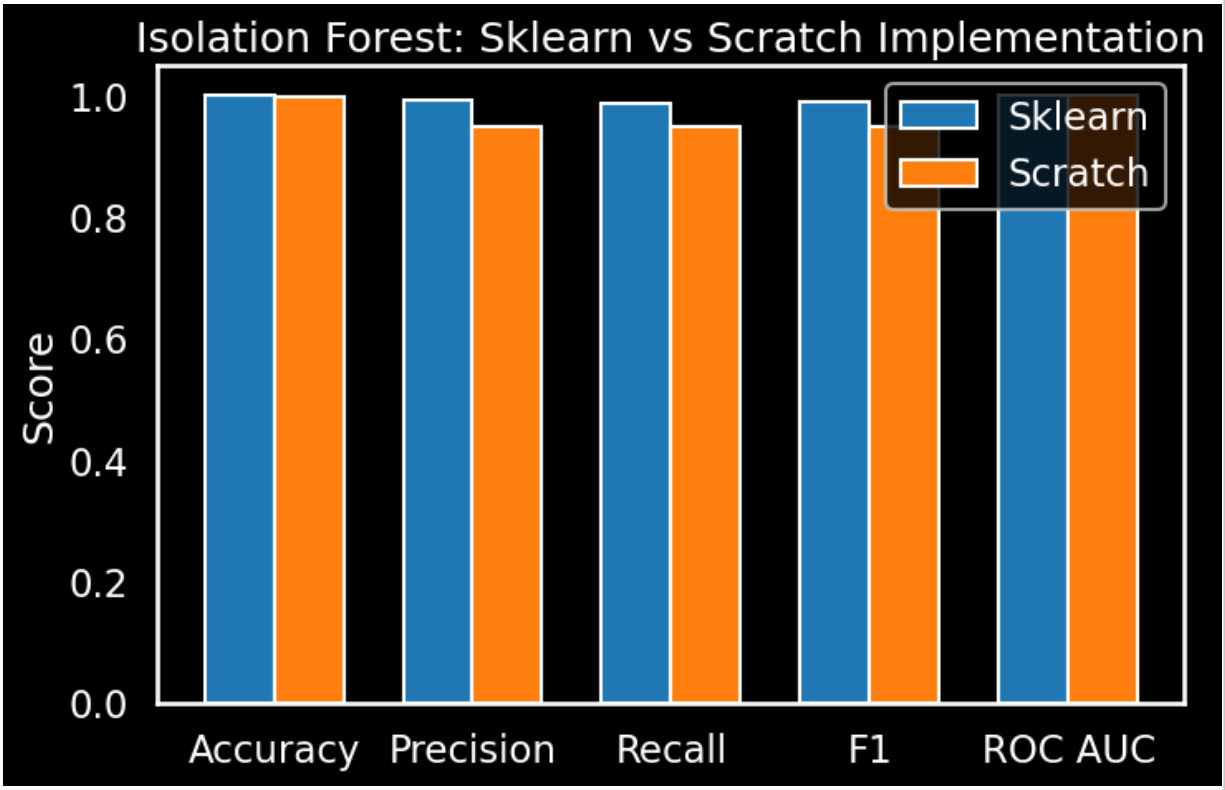


```
# ============================================================
# 1 — VALIDADOR DE TELEMETRIA
# ============================================================

class Validator:
```

```
    RULES = {
        'internal_temp':        {'type': 'range',  'min': 18,   'ma
        'external_temp':        {'type': 'range',  'min': -65,  'ma
        'structural_integrity': {'type': 'binary', 'expected': 1},
        'energy':               {'type': 'range',  'min': 60,   'ma
        'vibration':            {'type': 'range',  'min': 0.1,  'ma
        'tank_pressure':        {'type': 'range',  'min': 270,  'ma
        'critical_modules':     {'type': 'binary', 'expected': 1},
    }

    def __init__(self, df: pd.DataFrame):
        self.df = df

    def validate_item(self, item) -> bool:

        for col, rule in self.RULES.items():

            value = item[col]

            if rule['type'] == 'binary':
                if value != rule['expected']:
                    return False

            else:
                mn, mx = rule.get('min'), rule.get('max')

                if mn is not None and value < mn:
                    return False

                if mx is not None and value > mx:
                    return False

        return True

    def validate_item_detail(self, item):

        result = {}

        for col, rule in self.RULES.items():

            value = item[col]

            if rule['type'] == 'binary':

                result[col] = "OK" if value == rule['expected'] els

            else:
```

```
                mn, mx = rule.get('min'), rule.get('max')

                if mn is not None and value < mn:
                    result[col] = f"FAILED ({value} < {mn})"

                elif mx is not None and value > mx:
                    result[col] = f"FAILED ({value} > {mx})"

                else:
                    result[col] = "OK"

        return result


# ============================================================
# 2 — VERIFICAÇÃO DE IA
# ============================================================

def ai_anomaly_check(reading, model, scaler, threshold):

    print("\n=== IA ANOMALY CHECK ===")

    features = np.array([[
        reading["internal_temp"],
        reading["external_temp"],
        reading["structural_integrity"],
        reading["energy"],
        reading["vibration"],
        reading["tank_pressure"],
        reading["critical_modules"]
    ]])

    X_scaled = scaler.transform(features)

    score = model.anomaly_score(X_scaled)[0]

    print(f"Anomaly Score: {score:.4f}")

    if score >= threshold:
        print("⚠ IA detectou anomalia")
        return False

    print("IA não detectou anomalias")

    return True


# ============================================================
```

```
# 3 — ANÁLISE ENERGÉTICA
# ============================================================

def calculate_autonomy(
        capacity_kwh=18,
        charge_pct=100,
        loss_pct=14,
        launch_power_kw=2,
        launch_time_min=9,
        orbital_power_kw=1.2,
        min_launch_charge=95):

    print("\n=== ANÁLISE ENERGÉTICA ===")

    if charge_pct < min_launch_charge:
        print("Carga insuficiente para lançamento")
        return None

    available_energy = capacity_kwh * (charge_pct/100) * (1 - loss_

    launch_energy = launch_power_kw * (launch_time_min/60)

    autonomy = (available_energy - launch_energy) / orbital_power_k

    print(f"Energia disponível: {available_energy:.2f} kWh")
    print(f"Consumo no lançamento: {launch_energy:.2f} kWh")
    print(f"Autonomia orbital: {autonomy:.2f} h")

    return autonomy


# ============================================================
# 4 — DECISÃO FINAL
# ============================================================

def launch_decision(reading, model, scaler, threshold):

    print("\n==================================")
    print("AURORA SIGER — DECISÃO DE LANÇAMENTO")
    print("==================================")

    df = pd.DataFrame([reading])

    validator = Validator(df)

    print("\n=== TELEMETRIA ===")

    telemetry_ok = validator.validate_item(reading)
```

```
        details = validator.validate_item_detail(reading)

        for k, v in details.items():
            print(f"{k}: {v}")

        # IA
        ai_ok = ai_anomaly_check(reading, model, scaler, threshold)

        # Energia
        autonomy = calculate_autonomy(charge_pct=reading["energy"])

        # Decisão final
        if telemetry_ok and ai_ok and autonomy is not None:

            print("\n >>> PRONTO PARA DECOLAR <<<")

        else:

            print("\n >>> DECOLAGEM ABORTADA <<<")


    # ==============================================================
    # 5 — TESTE
    # ==============================================================

    sample_reading = {
        "internal_temp": 22.3,
        "external_temp": 12,
        "structural_integrity": 1,
        "energy": 98,
        "vibration": 0.32,
        "tank_pressure": 305,
        "critical_modules": 1
    }

    launch_decision(sample_reading, my_model, scaler, threshold)
```

```
==================================
AURORA SIGER — DECISÃO DE LANÇAMENTO
==================================

=== TELEMETRIA ===
internal_temp: OK
external_temp: OK
structural_integrity: OK
energy: OK
vibration: OK
```

```
    tank_pressure: OK
    critical_modules: OK

    === IA ANOMALY CHECK ===
    Anomaly Score: 0.3889
    IA não detectou anomalias

    === ANÁLISE ENERGÉTICA ===
    Energia disponível: 15.17 kWh
    Consumo no lançamento: 0.30 kWh
    Autonomia orbital: 12.39 h

     >>> PRONTO PARA DECOLAR <<<
```

```
algoritmo "Verificação de Decolagem Aurora SIGER"

variáveis

    internal_temp, external_temp: real
    structural_integrity, critical_modules: inteiro
    energy: real
    vibration: real
    tank_pressure: real

    telemetria_ok: lógico
    ia_ok: lógico
    autonomia: real

    // Constantes energéticas
    CAPACIDADE_KWH = 18
    PERDAS_PCT = 14
    POTENCIA_LANCAMENTO_KW = 2
    TEMPO_LANCAMENTO_MIN = 9
    POTENCIA_ORBITAL_KW = 1.2
    CARGA_MINIMA_LANCAMENTO = 95

início

    telemetria_ok = VERDADEIRO
    ia_ok = VERDADEIRO

    Escreva "=== SISTEMA AURORA SIGER - VERIFICAÇÃO PRÉ-DECOLAGEM ==="
```

```
// ==============================================================
// ETAPA 1 — Validação de Telemetria
// ==============================================================

Escreva "Lendo dados de telemetria..."

Leia internal_temp, external_temp, structural_integrity
Leia energy, vibration, tank_pressure, critical_modules

Se internal_temp < 18 OU internal_temp > 26 então
    Escreva "[ALERTA] Temperatura interna fora da faixa segura: ",
    telemetria_ok = FALSO
Fim_se

Se external_temp < -65 OU external_temp > 125 então
    Escreva "[ALERTA] Temperatura externa fora da faixa segura: ",
    telemetria_ok = FALSO
Fim_se

Se structural_integrity ≠ 1 então
    Escreva "[ALERTA] Falha na integridade estrutural detectada"
    telemetria_ok = FALSO
Fim_se

Se energy < 60 então
    Escreva "[ALERTA] Nível de energia abaixo do mínimo operaciona
    telemetria_ok = FALSO
Fim_se

Se vibration < 0.1 OU vibration > 0.5 então
    Escreva "[ALERTA] Vibração fora da faixa segura: ", vibration,
    telemetria_ok = FALSO
Fim_se

Se tank_pressure < 270 OU tank_pressure > 340 então
    Escreva "[ALERTA] Pressão dos tanques fora da faixa segura: ",
    telemetria_ok = FALSO
Fim_se

Se critical_modules ≠ 1 então
    Escreva "[ALERTA] Módulos críticos inativos"
```

```
        telemetria_ok = FALSO
    Fim_se

    // ============================================================
    // ETAPA 2 — Verificação IA (Isolation Forest)
    // ============================================================

    Escreva "Executando verificação de anomalias por IA..."

    leitura_normalizada = normalizar(leitura, scaler)
    score = modelo.anomaly_score(leitura_normalizada)

    Escreva "Anomaly Score: ", score

    Se score ≥ threshold então
        Escreva "[ALERTA] IA detectou anomalia"
        ia_ok = FALSO
    Senão
        Escreva "IA não detectou anomalias"
    Fim_se

    // ============================================================
    // ETAPA 3 — Análise Energética
    // ============================================================

    Escreva "Calculando autonomia energética..."

    Se energy < CARGA_MINIMA_LANCAMENTO então
        Escreva "[ALERTA] Carga insuficiente para lançamento: ", energ
        autonomia = NULO
    Senão
        disponivel = CAPACIDADE_KWH × (energy / 100) × (1 - PERDAS_PCT
        consumo_lancamento = POTENCIA_LANCAMENTO_KW × (TEMPO_LANCAMENT
        autonomia = (disponivel - consumo_lancamento) / POTENCIA_ORBIT

        Escreva "Energia disponível: ", disponivel, " kWh"
        Escreva "Consumo no lançamento: ", consumo_lancamento, " kWh"
        Escreva "Autonomia orbital: ", autonomia, " h"
    Fim_se

    // ============================================================
```

```
    // DECISÃO FINAL
    // ==============================================================

    Se telemetria_ok = VERDADEIRO E ia_ok = VERDADEIRO E autonomia ≠ N
        Escreva ">>> PRONTO PARA DECOLAR <<<"
    Senão
        Escreva ">>> DECOLAGEM ABORTADA <<<"
    Fim_se

Fim
```

Fluxograma do Algoritmo de Verificação

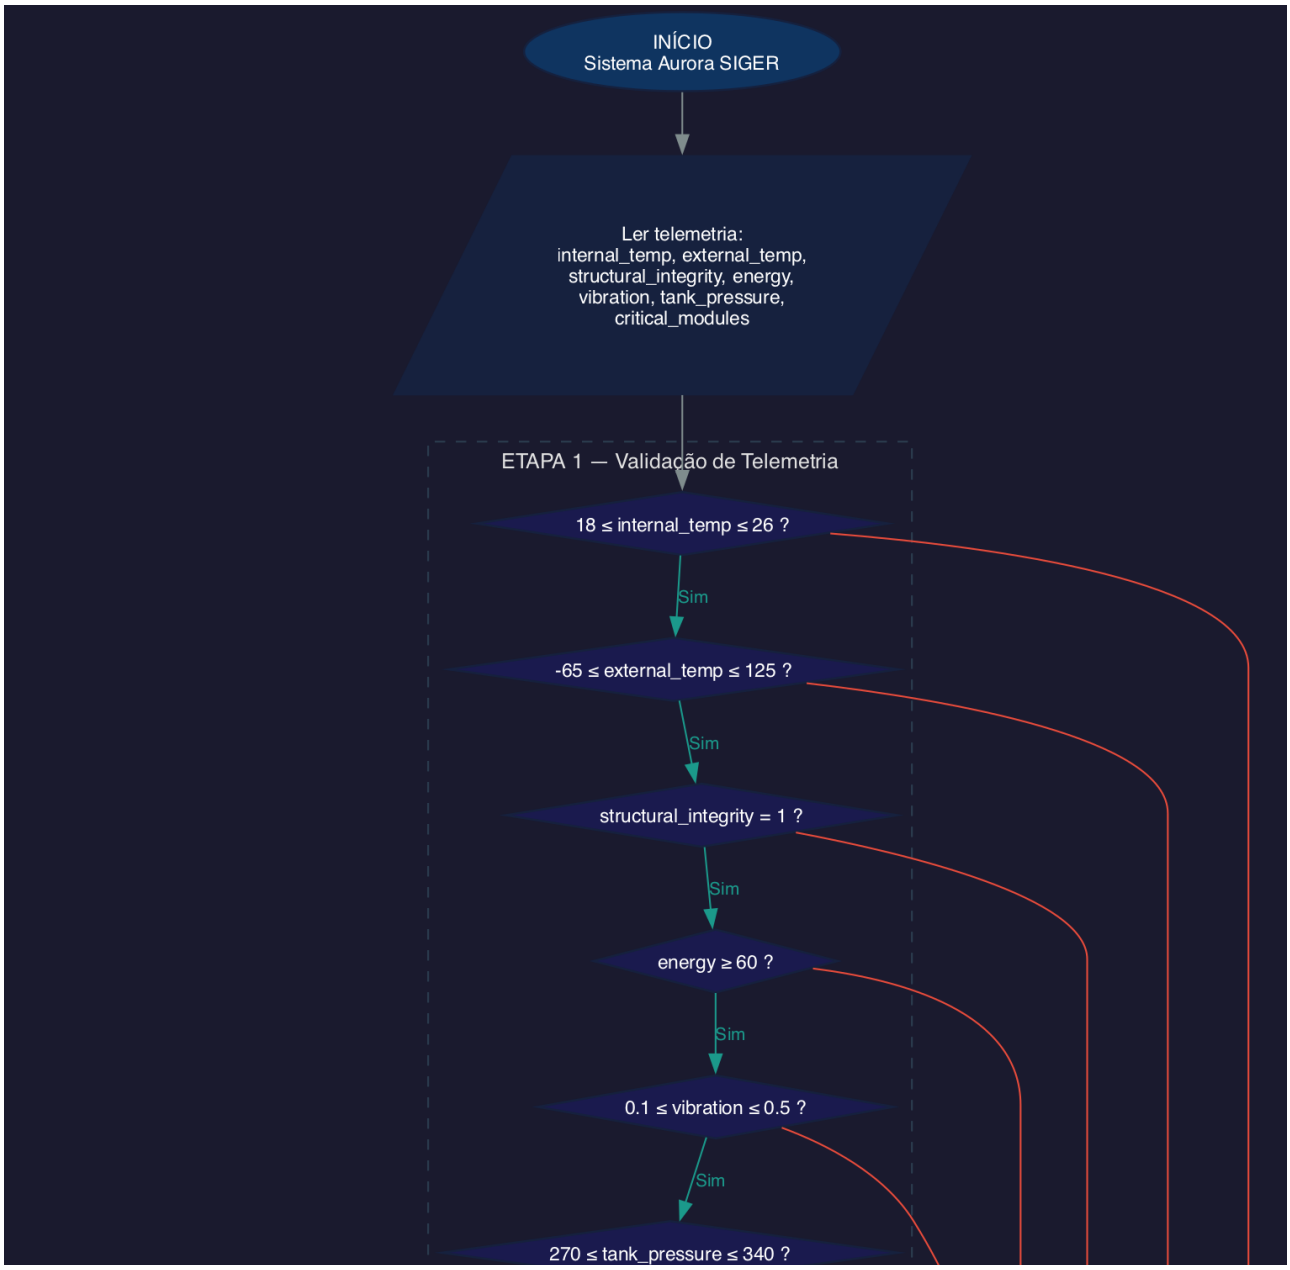

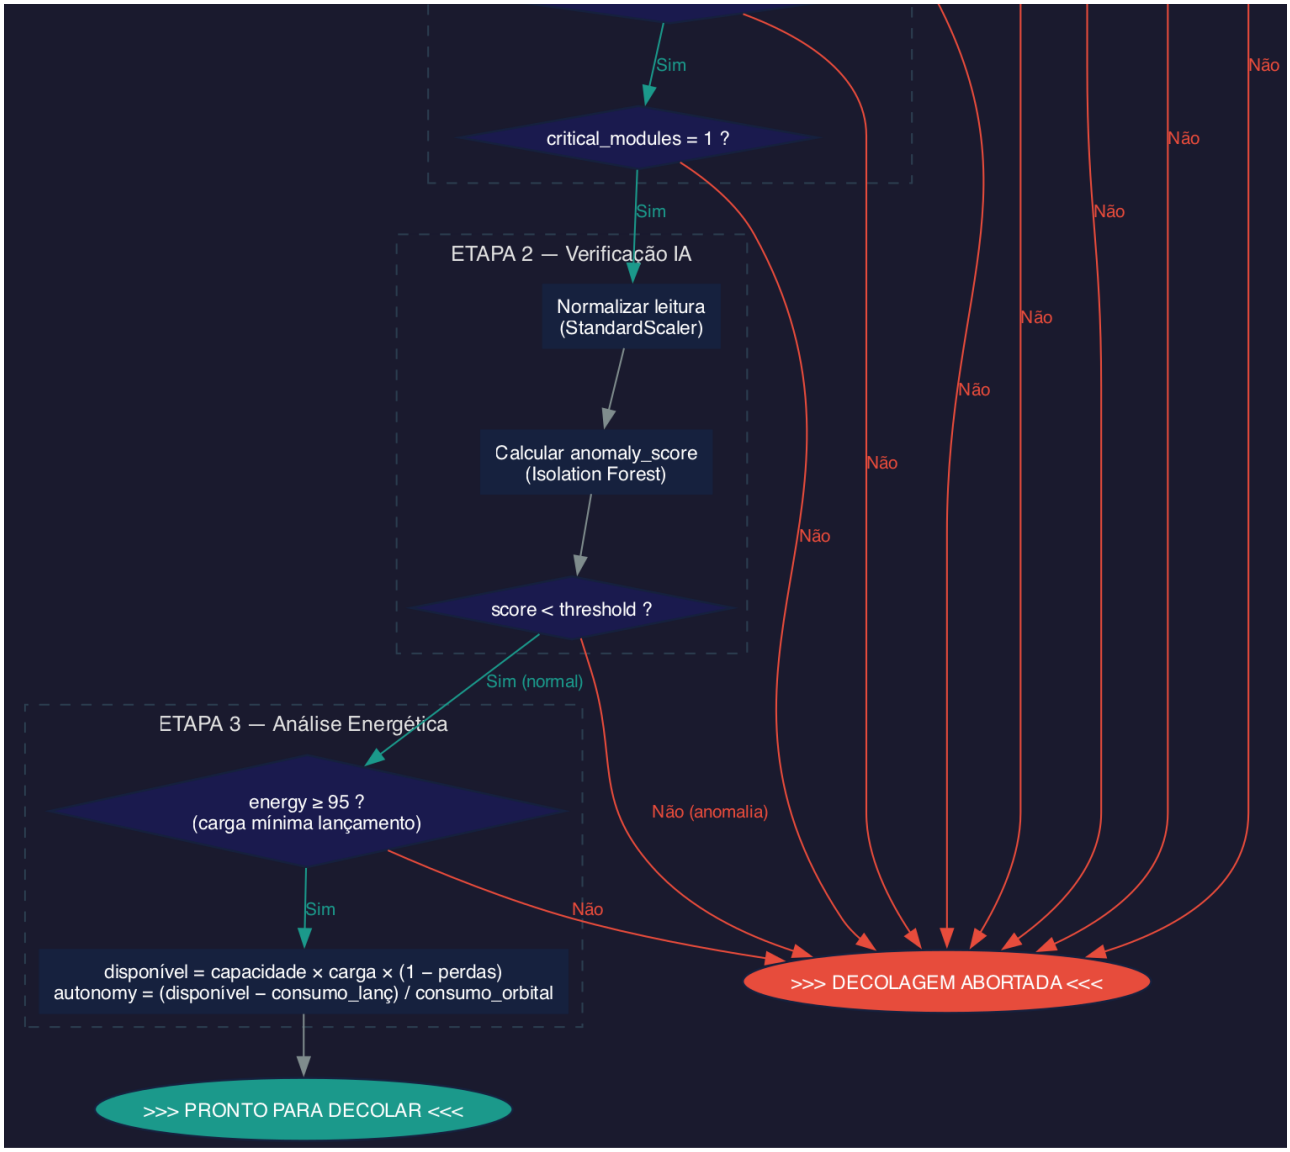

Considerações sobre o gerenciamento energético em foguetes espaciais

O gerenciamento energético de uma missão espacial é um exercício de engenharia de precisão onde cada quilowatt-hora conta. A capacidade total simulada neste projeto — 18 kWh, cobrindo cápsula e estágio superior — é comparável à de um carro elétrico urbano de entrada de gama. A diferença fundamental, porém, está no contexto: enquanto um veículo terrestre pode ser recarregado em qualquer ponto da rede elétrica, uma cápsula em órbita depende exclusivamente da energia embarcada até que os painéis solares sejam desdobrados e estabilizados. Essa limitação torna imperativo que sistemas como o Aurora SIGER monitorizem a carga em tempo real e imponham limiares rígidos de Go/No-Go — no nosso modelo, 95 % de carga pré-lançamento, alinhado com os ≥

97 % exigidos em missões tripuladas reais.

Alcançar níveis elevados de eficiência energética no espaço esbarra em restrições físicas severas. Baterias de lítio-íon, mesmo as de grau espacial, sofrem perdas por resistência interna (2–5 %) que se agravam com as variações térmicas extremas entre face solar e sombra orbital. A cadeia de conversão DC-DC, responsável por alimentar barramentos de 5 V e 12 V a partir do barramento principal de 28 VDC (MIL-STD-704F), consome entre 3 % e 8 % da energia. Somam-se as perdas em chicotes elétricos que podem ultrapassar 100 metros de comprimento (1–3 %), os sistemas de gestão térmica das próprias baterias (2–5 %) e o condicionamento de potência com reguladores e filtros de proteção (1–2 %). No total, as perdas do nosso modelo atingem 14 %, reduzindo a autonomia orbital estimada para cerca de 12 horas — uma janela que, embora suficiente para manobras iniciais, exige planeamento rigoroso de cada subsistema consumidor.

Essas restrições tornam-se ainda mais relevantes à luz dos planos da NASA de estabelecer presença humana contínua na Lua a partir de 2027, no âmbito do programa Artemis. Missões de longa duração demandarão avanços significativos em armazenamento energético, sistemas de recarga in situ e eficiência de conversão. A sustentabilidade da exploração espacial dependerá, em última análise, da capacidade de minimizar perdas e maximizar a autonomia com recursos finitos — precisamente o tipo de análise que ferramentas de telemetria como o Aurora SIGER pretendem viabilizar.

> **Fontes:** As referências completas dos parâmetros energéticos (SpaceX Crew Dragon Press Kit, NASA Orion MPCV, MIL-STD-704F, *Space Mission Engineering: The New SMAD*) encontram-se na secção **"Parâmetros energéticos"** do README.md.

Quem decide quando a máquina decide?

Sobre ética, automação e os limites do progresso — do algoritmo que nega seu crédito ao satélite que monitora o clima."

Você abre o celular e o feed já está montado — alguém decidiu o que você veria. Você pesquisa um voo e o preço muda na próxima visita — alguém decidiu quanto você pagaria. Você manda um currículo e ele desaparece antes de qualquer

humano ler — alguém decidiu que você não era relevante. Só que esse "alguém" não é uma pessoa. É um algoritmo — um conjunto de regras escritas por um programador, seguindo critérios definidos por uma empresa. A lógica está ali, mas a *intenção* por trás dela — por que esses critérios e não outros, a quem servem, o que otimizam — ficou na cabeça de quem projetou o sistema. Não há obrigação de torná-la visível. E é exatamente aí que mora o problema: as intenções embutidas em cada camada da cadeia tecnológica moldam silenciosamente o mundo que estamos construindo.

Não por acaso, esses modelos já foram chamados de "armas de destruição matemática" (O'Neil, 2016). São opacos, escaláveis e codificam preconceitos que já existiam na sociedade — mas agora operam em velocidade industrial. Você é avaliado, classificado e filtrado dezenas de vezes por dia — sem saber os critérios, sem poder contestar, e muitas vezes sem nem perceber que isso está acontecendo.

O problema não é a automação em si. É a ausência de transparência, responsabilidade e governança sobre ela.

Todo mundo concorda. Ninguém sabe como fazer.

Oitenta e quatro documentos de ética em inteligência artificial — de governos, empresas e instituições de pesquisa de dezenas de países — convergem em cinco princípios: transparência, justiça, não causar dano, responsabilidade e privacidade. Mas há divergência substancial sobre o que esses princípios significam na prática, quem deve implementá-los e como (Jobin, Ienca & Vayena, 2019).

Quase todo mundo concorda que a IA deveria ser justa e transparente. Quase ninguém concorda sobre o que fazer para garantir isso.

Enquanto essa lacuna persiste, há uma dimensão do problema que recebe ainda menos atenção: o custo energético. Cada modelo treinado, cada algoritmo rodando em um *data center*, cada busca processada consome eletricidade. Segundo estimativas de 2019, as emissões de gases de efeito estufa relacionadas a tecnologias de informação e comunicação cresciam cerca de 9% ao ano, e metade dessas emissões vinham da fabricação dos equipamentos (The Shift Project, 2019). A eficiência energética não é um detalhe técnico — é uma questão ética. Cada watt desperdiçado por um sistema mal otimizado é um recurso natural que não volta.

E aqui surge uma tensão produtiva: a mesma tecnologia que consome energia massiva também pode ser usada para reduzi-la. Algoritmos de aprendizado de máquina já otimizam redes elétricas, preveem padrões de consumo e controlam a refrigeração de grandes centros de processamento de dados. Um exemplo: o *data center* do Google em Hamina, na Finlândia, usa água do mar gelada para resfriar seus servidores e inteligência artificial para ajustar o sistema em tempo real. O resultado é que a esmagadora maioria da energia consumida vai direto para o processamento — uma fração mínima é gasta com refrigeração e infraestrutura auxiliar. O que muda o jogo não é a tecnologia em si, mas a decisão de empregá-la para otimizar em vez de desperdiçar.

Essa distinção — entre uso que cria e uso que extrai — aparece também na pesquisa sobre cognição. Uma meta-análise com mais de 411 mil adultos demonstrou que o uso *ativo* de tecnologia digital (aprender, resolver problemas, manter conexões) reduz em 58% o risco de declínio cognitivo, um efeito protetor comparável ao do exercício físico. O uso passivo e compulsivo, por outro lado, está associado a déficits mensuráveis em atenção e função executiva (Benge & Scullin, 2025; Throuvala et al., 2023). A mesma tela, o mesmo algoritmo — intenções diferentes, consequências opostas.

Quando a fronteira reproduz a desigualdade

Se a ética da automação parece um problema abstrato, a exploração espacial oferece um caso concreto em que todas essas tensões se materializam.

Considere o programa Apollo. Custou mais de US $25 bilhões nos anos 1960 — aproximadamente US$ 260 bilhões em valores atuais. A economista Mariana Mazzucato argumenta que o retorno desse investimento superou amplamente o custo, e usa o Apollo como modelo para o tipo de inovação que precisamos: audaciosa, orientada por missões claras, com colaboração real entre Estado e setor privado (Mazzucato, 2021).

Os benefícios concretos são documentados: o programa espacial americano como um todo já transferiu mais de 2.000 tecnologias para uso civil — de sensores de câmera de celular a sistemas de purificação de água, de espuma viscoelástica a equipamentos de proteção para bombeiros (NASA Spinoff). A exploração espacial não é luxo — é investimento com retorno mensurável.

Mas a pergunta que geralmente não se faz é: *quem* colhe esses retornos?

Se apenas países e empresas com capital massivo podem acessar recursos espaciais — mineração de asteroides, turismo orbital, satélites de comunicação —, o espaço reproduz no vácuo a mesma desigualdade que já existe na Terra. Joseph Pelton chama a corrida espacial privada de "nova corrida do ouro" — e aponta que, sem governança, seus benefícios se concentrarão ainda mais (Pelton, 2017). O Tratado do Espaço Exterior de 1967 estabeleceu que o espaço é patrimônio de toda a humanidade e não pode ser reivindicado como território por nenhuma nação — mas a exploração comercial de seus recursos opera em zona cinzenta jurídica, e esse princípio está sendo testado como nunca.

O dilema é familiar: investimento público gera inovação transformadora, mas se a governança falha, os benefícios se privatizam e os custos se socializam. Exatamente como nos algoritmos que decidem sobre vidas sem prestar contas.

A pergunta que atravessa tudo

Se há um fio que conecta a opacidade dos algoritmos, o consumo energético dos *data centers* e a corrida comercial pelo espaço, é este: **eficiência sem ética é apenas uma forma mais sofisticada de desperdício**.

Um algoritmo que otimiza lucro mas amplifica desigualdade não é eficiente — é destrutivo em escala. Um *data center* que processa bilhões de operações mas ignora sua pegada de carbono não é moderno — é insustentável. Uma indústria espacial que gera tecnologias transformadoras mas concentra seus benefícios não é inovadora — é extrativista.

E isso não é problema de especialista. É problema de qualquer pessoa que usa um celular, abre uma rede social ou paga um boleto — ou seja, de praticamente todo mundo. A exploração espacial, a regulamentação da IA e a eficiência energética parecem temas distantes, mas são, na verdade, questões sobre quem tem poder de decidir sobre a sua vida sem precisar pedir permissão.

A pergunta que vale a pena fazer — sobre automação, energia, espaço e tudo o mais — não é "essa tecnologia funciona?", mas "para quem funciona, com que transparência e sob qual governança?"

> A pergunta que vale a pena fazer sobre qualquer tecnologia não é "funciona?", mas "quem decidiu que deveria funcionar assim — e para quem?"